

script_python

November 28, 2025

```
[2]: # Manipulação de Dados
import pandas as pd
import numpy as np

# Visualização
import matplotlib.pyplot as plt
import matplotlib.cm as cm
import seaborn as sns

# Métricas e Transformações
from sklearn.metrics import mean_absolute_error, mean_squared_error
from scipy.special import inv_boxcox
from scipy import stats

# Modelos e Ferramentas de Séries Temporais
from statsmodels.tsa.seasonal import STL
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
from statsmodels.tsa.stattools import acf, pacf
from statsmodels.tsa.api import SARIMAX
from statsmodels.tsa.holtwinters import ExponentialSmoothing

# Bibliotecas Específicas de Time Series
import pmdarima as pm
from sktime.transformations.series.boxcox import BoxCoxTransformer
from statsforecast import StatsForecast
from statsforecast.models import AutoETS

# CONFIGURAÇÕES GLOBAIS
sns.set_theme(style="whitegrid", palette="muted")
plt.rcParams['figure.figsize'] = (12, 6)
```

```
[3]: # 1. Carregar o dataset consolidado
df = pd.read_excel("dataset_st.xlsx")

# 2. Tratamento básico (Garantir formato de data)
if 'data' not in df.columns:
    df = df.rename(columns={'mes': 'data', 'Data': 'data', 'Date': 'data'})
```

```

df['data'] = pd.to_datetime(df['data'])

# Selecionar colunas e garantir ordenação
df = df[['data', 'co2_mt']].sort_values('data').reset_index(drop=True)

# 3. Filtrar período de interesse (a partir de 2008)
df_focado = df[df['data'] >= '2008-01-01'].copy()

# 4. Dividir Treino e Teste
data_corte = '2023-12-31'

treino = df_focado[df_focado['data'] <= data_corte].set_index('data')['co2_mt']
teste = df_focado[df_focado['data'] > data_corte].set_index('data')['co2_mt']

# Verificação final
print(f"Dataset carregado: dataset_st.xlsx")
print(f"Treino: {treino.shape[0]} obs (até {treino.index.max().date()})")
print(f"Teste: {teste.shape[0]} obs (a partir de {teste.index.min().date()})")

```

Dataset carregado: dataset_st.xlsx
Treino: 192 obs (até 2023-12-01)
Teste: 22 obs (a partir de 2024-01-01)

```

[8]: # Configurar a figura
fig, ax = plt.subplots(figsize=(12, 6))

# Plotar a série completa
ax.plot(df['data'], df['co2_mt'], linestyle='-', color='tab:blue',  

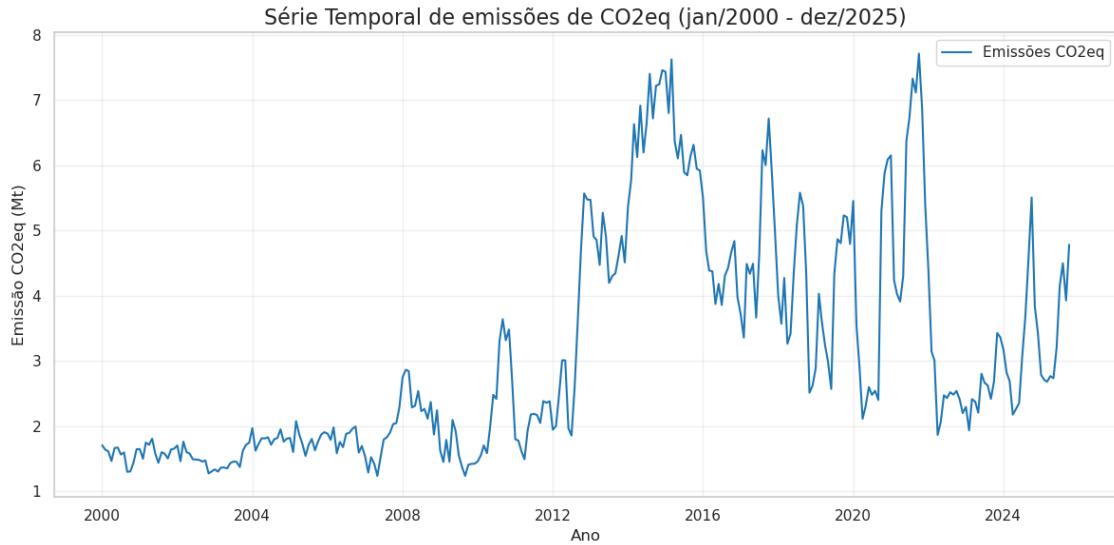
        label='Emissões CO2eq')

# Estilização do gráfico
ax.set_title('Série Temporal de emissões de CO2eq (jan/2000 - dez/2025)',  

            fontsize=16)
ax.set_ylabel('Emissão CO2eq (Mt)')
ax.set_xlabel('Ano')
ax.grid(True, alpha=0.3)
ax.legend()

plt.tight_layout()
plt.show()

```

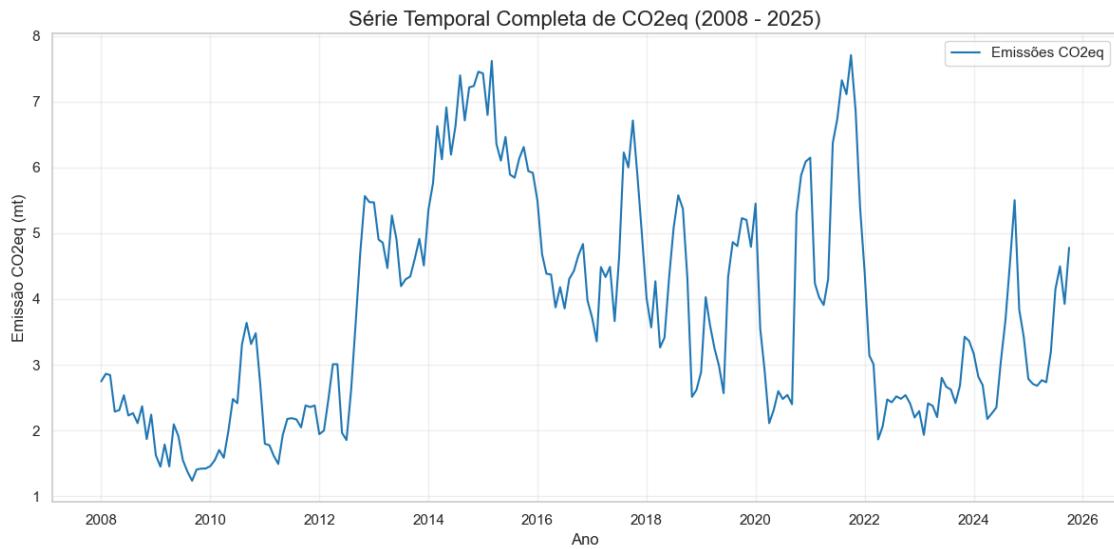


```
[ ]: # Configurar a figura
fig, ax = plt.subplots(figsize=(12, 6))

# Plotar a série completa
ax.plot(df_focado['data'], df_focado['co2_mt'], linestyle='-', color='tab:blue', label='Emissões CO2eq')

# Estilização do gráfico
ax.set_title('Série Temporal Completa de CO2eq (2008 - 2025)', fontsize=16)
ax.set_ylabel('Emissão CO2eq (mt)')
ax.set_xlabel('Ano')
ax.grid(True, alpha=0.3)
ax.legend()

plt.tight_layout()
plt.show()
```



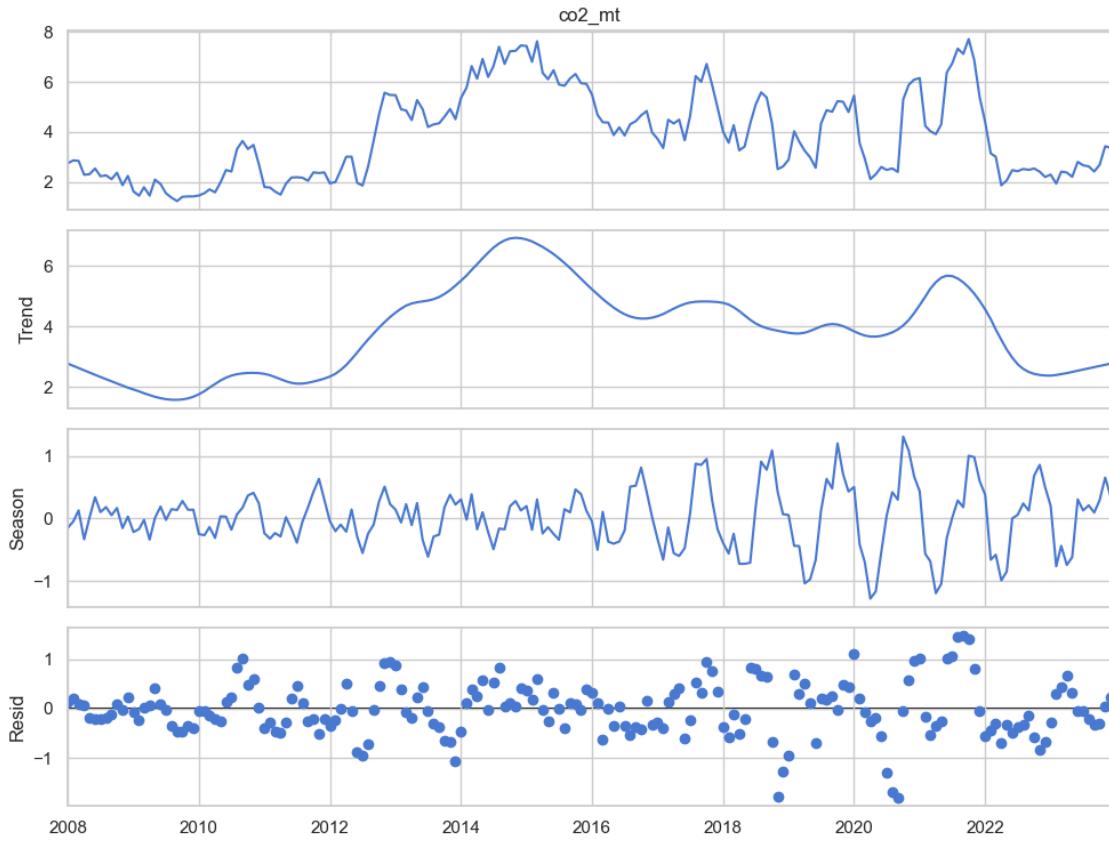
```
[ ]: # Decomposição STL

# Aplicar STL (period=12 para dados mensais)
stl = STL(treino, period=12)
result = stl.fit()

# Plotar os componentes (Observado, Tendência, Sazonalidade, Resíduos)
fig = result.plot()
fig.set_size_inches(10, 8)

# Ajustes visuais
plt.suptitle('Decomposição STL da Série de Treino (2008-2023) - CO2eq', y=1.02,
             fontsize=16)
plt.tight_layout()
plt.show()
```

Decomposição STL da Série de Treino (2008-2023) - CO2eq



```
[ ]: # 1. Instanciar o transformador Guerrero (sp=12)
transformer = BoxCoxTransformer(method='guerrero', sp=12)

# 2. Fit no treino para achar o Lambda
transformer.fit(treino)
lambda_guerrero = transformer.lambda_

# 3. Transformar a série de treino
treino_guerrero = transformer.transform(treino)
treino_guerrero = pd.Series(treino_guerrero.values.flatten(), index=treino.
                           index)

print(f"Lambda ótimo encontrado (Guerrero): {lambda_guerrero:.4f}")

# Visualização Comparativa
fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(15, 5))

# Original
```

```

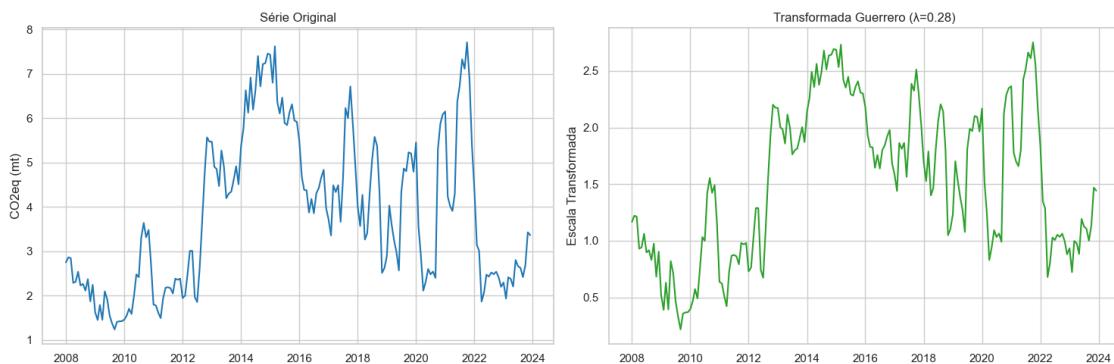
ax1.plot(treino, color='tab:blue')
ax1.set_title('Série Original')
ax1.set_ylabel('CO2eq (mt)')

# Transformada
ax2.plot(treino_guerrero, color='tab:green')
ax2.set_title(f'Transformada Guerrero ( ={lambda_guerrero:.2f})')
ax2.set_ylabel('Escala Transformada')

plt.tight_layout()
plt.show()

```

Lambda ótimo encontrado (Guerrero): 0.2786



[]: # Comparação das Decomposições STL (Original vs. Guerrero)

```

# 1. Calcular o STL da série transformada
stl_guerrero = STL(treino_guerrero, period=12)
result_guerrero = stl_guerrero.fit()

# 2. Criar figura 4x2
fig, axes = plt.subplots(4, 2, figsize=(16, 12), sharex=True)

# Coluna 1: Série Original

# Observado

axes[0, 0].plot(result.observed, color='tab:blue')

axes[0, 0].set_title('Original: Observado')

axes[0, 0].set_ylabel('CO2eq (mt)')

axes[0, 0].grid(True, alpha=0.3)

```

```

# Tendência

axes[1, 0].plot(result.trend, color='tab:blue')

axes[1, 0].set_title('Original: Tendência')

axes[1, 0].set_ylabel('CO2eq (mt)')

axes[1, 0].grid(True, alpha=0.3)

# Sazonalidade

axes[2, 0].plot(result.seasonal, color='tab:blue')

axes[2, 0].set_title('Original: Sazonalidade')

axes[2, 0].set_ylabel('CO2eq (mt)')

axes[2, 0].grid(True, alpha=0.3)

# Resíduos (Scatter plot)

axes[3, 0].scatter(result.resid.index, result.resid.values, s=10, alpha=0.7, color='tab:blue')

axes[3, 0].set_title('Original: Resíduos')

axes[3, 0].set_ylabel('CO2eq (mt)')

axes[3, 0].axhline(0, color='red', linestyle='--', alpha=0.7)

axes[3, 0].grid(True, alpha=0.3)

axes[3, 0].set_xlabel('Data')

#Coluna 2: Série Transformada (Guerrero)

# Observado

axes[0, 1].plot(result_guerrero.observed, color='tab:green')

axes[0, 1].set_title(f'Guerrero ({lambda_guerrero:.2f}): Observado')

axes[0, 1].set_ylabel('Valor Transformado')

axes[0, 1].grid(True, alpha=0.3)

```

```

# Tendência

axes[1, 1].plot(result_guerrero.trend, color='tab:green')

axes[1, 1].set_title(f'Guerrero ( ={lambda_guerrero:.2f}): Tendência')

axes[1, 1].set_ylabel('Valor Transformado')

axes[1, 1].grid(True, alpha=0.3)

# Sazonalidade

axes[2, 1].plot(result_guerrero.seasonal, color='tab:green')

axes[2, 1].set_title(f'Guerrero ( ={lambda_guerrero:.2f}): Sazonalidade')

axes[2, 1].set_ylabel('Valor Transformado')

axes[2, 1].grid(True, alpha=0.3)

# Resíduos (Scatter plot)

axes[3, 1].scatter(result_guerrero.resid.index, result_guerrero.resid.values, s=10, alpha=0.7, color='tab:green')

axes[3, 1].set_title(f'Guerrero ( ={lambda_guerrero:.2f}): Resíduos')

axes[3, 1].set_ylabel('Valor Transformado')

axes[3, 1].axhline(0, color='red', linestyle='--', alpha=0.7)

axes[3, 1].grid(True, alpha=0.3)

axes[3, 1].set_xlabel('Data')

# plot

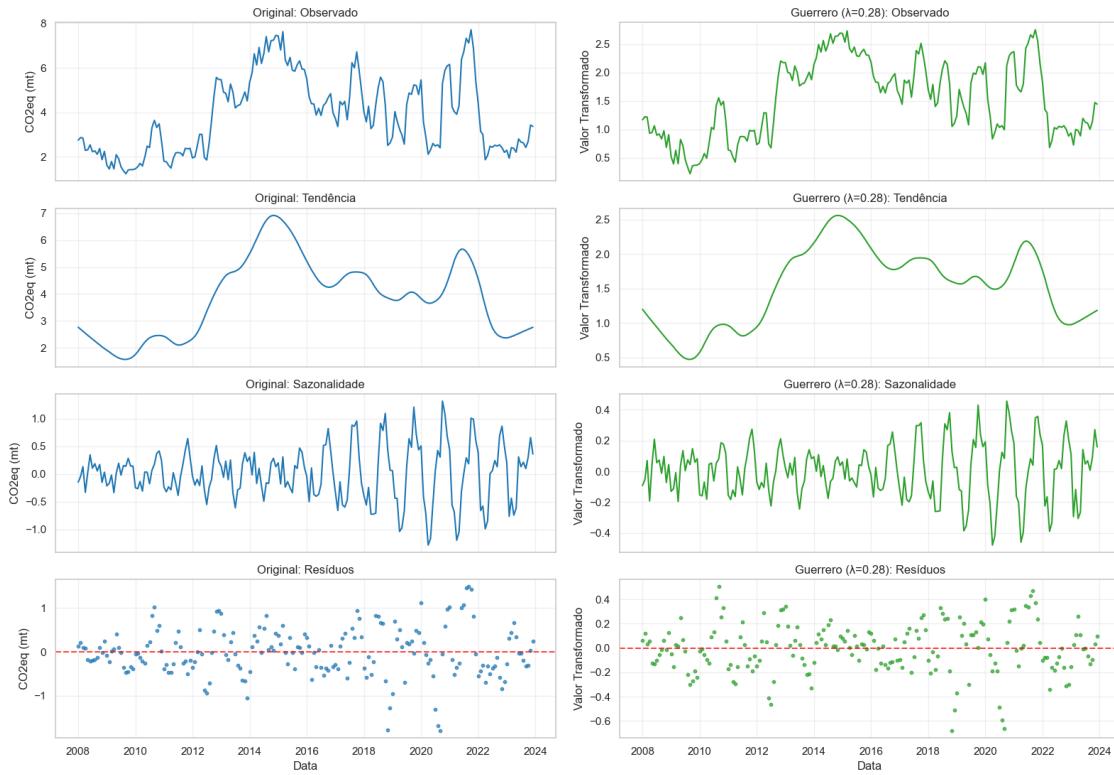
plt.suptitle('Comparação das Decomposições STL: Original vs. Box-Cox (Guerrero)', fontsize=18)

plt.tight_layout(rect=[0, 0, 1, 0.96])

plt.show()

```

Comparação das Decomposições STL: Original vs. Box-Cox (Guerrero)



[]: # ACF e PACF da Série Transformada (Guerrero) no Estilo Spike

```
# 1. Calcular os valores de ACF e PACF
lags = 48
acf_vals = acf(treino_guerrero, nlags=lags)
pacf_vals = pacf(treino_guerrero, nlags=lags)

# 2. Calcular o intervalo de confiança
n_obs = len(treino_guerrero)
conf_interval = 1.96 / np.sqrt(n_obs)

# 3. Criar a figura com dois subplots
fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(16, 6))

# Gráfico 1: ACF (Estilo "Spike")
ax1.stem(range(len(acf_vals)), acf_vals, linefmt='b-', markerfmt='bo', basefmt='r-')
ax1.set_title('Função de Autocorrelação (ACF)')
ax1.set_xlabel('Defasagem (Lags)')
ax1.set_ylabel('Autocorrelação')

# Gráfico 2: PACF (Estilo "Spike")
ax2.stem(range(len(pacf_vals)), pacf_vals, linefmt='b-', markerfmt='bo', basefmt='r-')
ax2.set_title('Função de Autocorrelação Parcial (PACF)')
ax2.set_xlabel('Defasagem (Lags)')
ax2.set_ylabel('Autocorrelação Parcial')
```

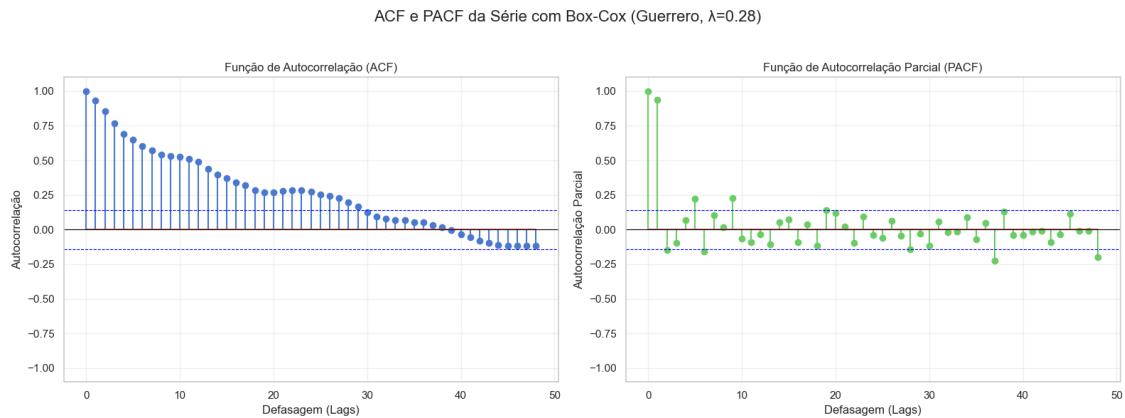
```

ax1.axhline(0, color='black', linewidth=0.8)
ax1.axhline(conf_interval, color='blue', linestyle='--', linewidth=0.8)
ax1.axhline(-conf_interval, color='blue', linestyle='--', linewidth=0.8)
ax1.set_ylim(-1.1, 1.1)
ax1.grid(True, alpha=0.3)

# Gráfico 2: PACF (Estilo Spike)
ax2.stem(range(len(pacf_vals)), pacf_vals, linefmt='g-', markerfmt='go', basefmt='r-')
ax2.set_title('Função de Autocorrelação Parcial (PACF)')
ax2.set_xlabel('Defasagem (Lags)')
ax2.set_ylabel('Autocorrelação Parcial')
ax2.axhline(0, color='black', linewidth=0.8)
ax2.axhline(conf_interval, color='blue', linestyle='--', linewidth=0.8)
ax2.axhline(-conf_interval, color='blue', linestyle='--', linewidth=0.8)
ax2.set_ylim(-1.1, 1.1)
ax2.grid(True, alpha=0.3)

# Título geral e layout
lambda_round = np.round(lambda_guerrero, 2)
plt.suptitle(f'ACF e PACF da Série com Box-Cox (Guerrero, ={lambda_round}:.2f)', fontsize=16)
plt.tight_layout(rect=[0, 0, 1, 0.95])
plt.show()

```



[36]: # Aplicando Diferenciação ($d=1$ e $D=1$)

```

# 1. Aplicar diferenciação sazonal ( $D=1$ ,  $m=12$ ) e depois não sazonal ( $d=1$ ).

# O .dropna() é crucial para remover os 13 valores NaN gerados pelas
# diferenças.
serie_diff = treino_guerrero.diff(12).diff(1).dropna()

```

```

# 2. Calcular os valores de ACF e PACF para a série diferenciada
lags = 48
acf_vals_diff = acf(serie_diff, nlags=lags)
pacf_vals_diff = pacf(serie_diff, nlags=lags)

# 3. Recalcular o intervalo de confiança () pois removemos 13 observações)
n_obs_diff = len(serie_diff)
conf_interval_diff = 1.96 / np.sqrt(n_obs_diff)

# 4. Plotagem dos Gráficos ACF e PACF da Série Diferenciada
# Criar a figura com os novos gráficos
fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(16, 6))

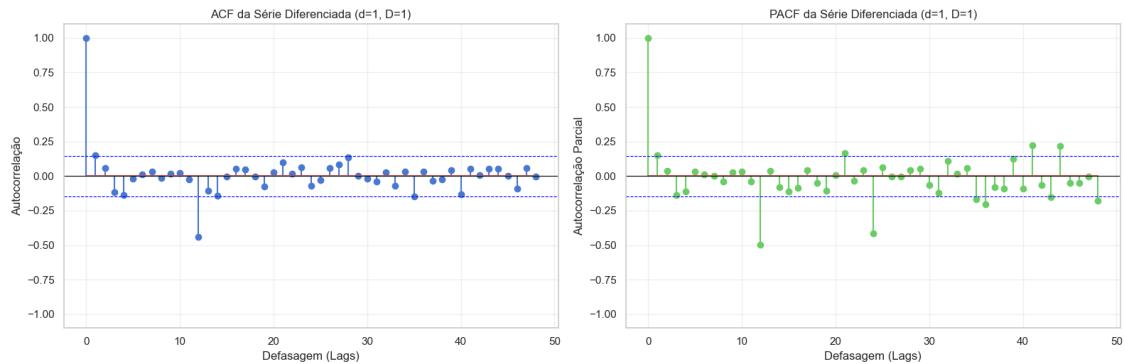
# 4. Gráfico 1: ACF da Série Diferenciada (Estilo "Spike")
ax1.stem(range(len(acf_vals_diff)), acf_vals_diff, linefmt='b-', □
         markerfmt='bo', basefmt='r-')
ax1.set_title('ACF da Série Diferenciada (d=1, D=1)')
ax1.set_xlabel('Defasagem (Lags)')
ax1.set_ylabel('Autocorrelação')
ax1.grid(True, alpha=0.3)
ax1.axhline(0, color='black', linewidth=0.8)
ax1.axhline(conf_interval_diff, color='blue', linestyle='--', linewidth=0.8)
ax1.axhline(-conf_interval_diff, color='blue', linestyle='--', linewidth=0.8)
ax1.set_ylim(-1.1, 1.1)

# Gráfico 2: PACF da Série Diferenciada (Estilo "Spike")
ax2.stem(range(len(pacf_vals_diff)), pacf_vals_diff, linefmt='g-', □
         markerfmt='go', basefmt='r-')
ax2.set_title('PACF da Série Diferenciada (d=1, D=1)')
ax2.set_xlabel('Defasagem (Lags)')
ax2.set_ylabel('Autocorrelação Parcial')
ax2.grid(True, alpha=0.3)
ax2.axhline(0, color='black', linewidth=0.8)
ax2.axhline(conf_interval_diff, color='blue', linestyle='--', linewidth=0.8)
ax2.axhline(-conf_interval_diff, color='blue', linestyle='--', linewidth=0.8)
ax2.set_ylim(-1.1, 1.1)

plt.suptitle('Análise após Diferenciação (Série Box-Cox Estacionária)', □
             fontsize=16)
plt.tight_layout(rect=[0, 0, 1, 0.95])
plt.show()

```

Análise apóis Diferenciação (Série Box-Cox Estacionária)



```
[41]: # Modelo SARIMA Manual
modelo_manual_pm = pm.ARIMA(
    order=(0, 1, 0),                      # (p, d, q)
    seasonal_order=(2, 1, 1, 12),           # (P, D, Q, m)
    suppress_warnings=True                 # Ignora avisos de convergência irrelevantes
)

modelo_manual_pm.fit(treino_guerrero)

print(modelo_manual_pm.summary())

# Previsão e Inversão da Transformação

n_periodos = len(teste)

pred_boxcox, conf_int_boxcox = modelo_manual_pm.predict(
    n_periods=n_periodos,
    return_conf_int=True,
    alpha=0.05
)

# Reverter Box-Cox (Voltar para a escala original)
pred_final_manual = inv_boxcox(pred_boxcox, lambda_guerrero)
conf_int_final_manual = inv_boxcox(conf_int_boxcox, lambda_guerrero)

# Avaliação de Métricas

mae_manual = mean_absolute_error(teste, pred_final_manual)
rmse_manual = np.sqrt(mean_squared_error(teste, pred_final_manual))

print(f"\n--- Resultados Modelo Manual ---")
print(f"MAE: {mae_manual:.4f}")
```

```

print(f"RMSE: {rmse_manual:.4f}")

# Plot

fig, ax = plt.subplots(figsize=(14, 7))

# Dados de Treino
ax.plot(treino.index[-48:], treino.tail(48), label='Treino', color='tab:blue')

# Dados Reais
ax.plot(teste.index, teste, label='Teste', color='black', linewidth=2)

# Previsão
ax.plot(teste.index, pred_final_manual, label='Previsão Manual', color='green',  

    linestyle='--')

# Intervalo de Previsão
ax.fill_between(
    teste.index,
    conf_int_final_manual[:, 0],
    conf_int_final_manual[:, 1],
    color='purple', alpha=0.2, label='IP 95%'
)

ax.set_title(f'Previsão Manual (0,1,0)(2,1,1)[12] ({lambda_guerrero:.2f})',  

    fontsize=16)
ax.set_ylabel('Emissão CO2eq (mt)')
ax.legend(loc='upper left')
ax.grid(True, alpha=0.3)

plt.tight_layout()
plt.show()

# Diagnósticos
modelo_manual_pm.plot_diagnostics(figsize=(15, 10))
plt.suptitle('Diagnóstico de Resíduos - Modelo Manual', y=1.02)
plt.show()

```

SARIMAX Results

```

=====
=====
Dep. Variable:                      y      No. Observations:      192
Model:                 SARIMAX(0, 1, 0)x(2, 1, [1], 12)   Log Likelihood   -4.550
Date:                    Fri, 21 Nov 2025      AIC
19.100

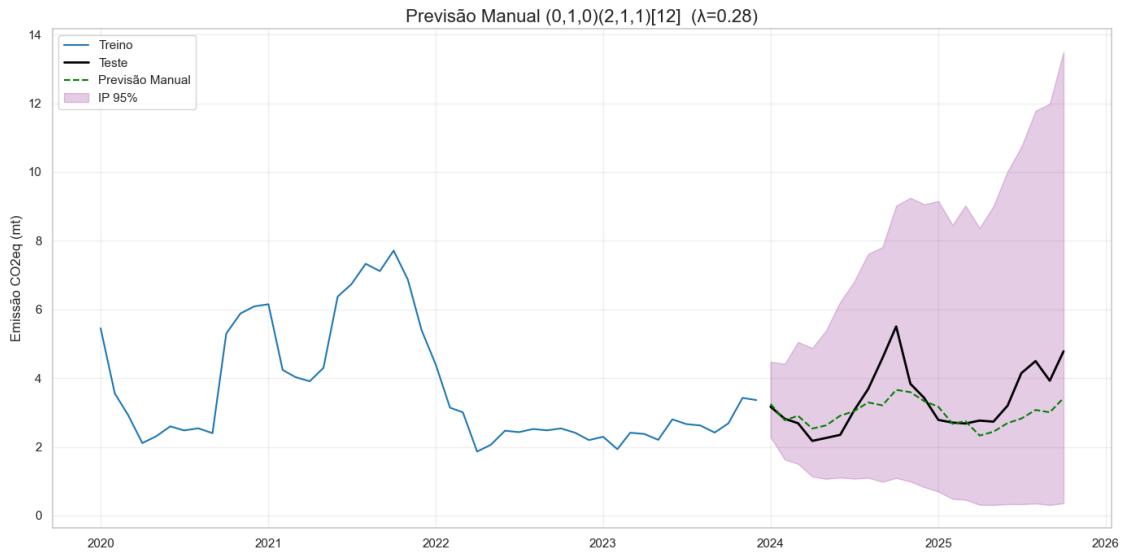
```

```

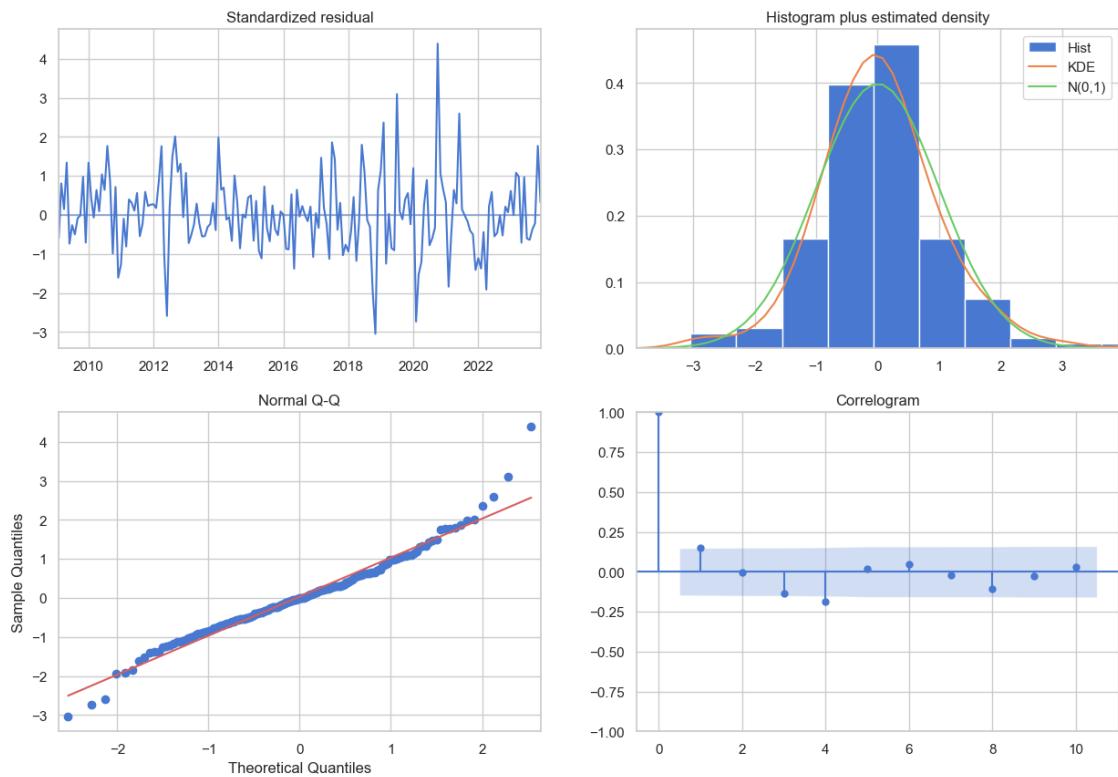
Time: 20:09:27 BIC
35.037
Sample: 01-01-2008 HQIC
25.562 - 12-01-2023
Covariance Type: opg
=====
          coef    std err      z   P>|z|   [0.025   0.975]
-----
intercept -0.0008    0.004  -0.188    0.851  -0.009    0.008
ar.S.L12   0.0124    0.137   0.090    0.928  -0.257    0.282
ar.S.L24   -0.0544   0.111  -0.490    0.624  -0.272    0.163
ma.S.L12   -0.8475   0.146  -5.816    0.000  -1.133   -0.562
sigma2     0.0564    0.005  12.225    0.000   0.047    0.065
=====
===
Ljung-Box (L1) (Q): 3.99 Jarque-Bera (JB):
42.59
Prob(Q): 0.05 Prob(JB):
0.00
Heteroskedasticity (H): 1.76 Skew:
0.45
Prob(H) (two-sided): 0.03 Kurtosis:
5.21
=====
===
Warnings:
[1] Covariance matrix calculated using the outer product of gradients (complex-step).

--- Resultados Modelo Manual ---
MAE: 0.5602
RMSE: 0.7771

```



Diagnóstico de Resíduos - Modelo Manual



```
[40]: # Treinamento Auto-ARIMA (d=1 fixo, D automático)

# Configuração
modelo_auto_d_travado = pm.auto_arima(
    treino_guerrero,                      # Série transformada
    start_p=0, start_q=0,
    max_p=3, max_q=3,
    m=12,                                # Período sazonal
    start_P=0,
    seasonal=True,                         # Habilita o SARIMA
    d=1,                                   # Força diferenciação de tendência
    D=None,                               # Deixa o teste encontrar o D
    seasonal_test='ocsb',                  # Teste específico para sazonalidade
    trace=True,
    error_action='ignore',
    suppress_warnings=True,
    stepwise=True
)

print("\n--- Melhor modelo encontrado ---")
print(modelo_auto_d_travado.summary())

# Previsão e Inversão da Transformação

n_periodos = len(teste)

# Gerar previsões
pred_boxcox_auto, conf_int_boxcox_auto = modelo_auto_d_travado.predict(
    n_periods=n_periodos,
    return_conf_int=True,
    alpha=0.05
)

# Reverter Box-Cox (Voltar para CO2eq real)
pred_final_auto = inv_boxcox(pred_boxcox_auto, lambda_guerrero)
conf_int_final_auto = inv_boxcox(conf_int_boxcox_auto, lambda_guerrero)

# Avaliação de Métricas

mae_auto = mean_absolute_error(teste, pred_final_auto)
rmse_auto = np.sqrt(mean_squared_error(teste, pred_final_auto))

print(f"\n--- Resultados Auto-ARIMA (d=1, D=auto) ---")
print(f"MAE: {mae_auto:.4f}")
print(f"RMSE: {rmse_auto:.4f}")

# Gráfico 1: Previsão vs Real
```

```

fig, ax = plt.subplots(figsize=(14, 7))

# Dados de Treino
ax.plot(treino.index[-48:], treino.tail(48), label='Treino (Últimos 4 anos)', color='tab:blue')

# Dados Reais (Teste)
ax.plot(teste.index, teste, label='Real (Teste)', color='black', linewidth=2)

# Previsão
ax.plot(teste.index, pred_final_auto, label=f'Previsão Auto-ARIMA',
        color='green', linestyle='--')

# Intervalo de Previsão
ax.fill_between(
    teste.index,
    conf_int_final_auto[:, 0],
    conf_int_final_auto[:, 1],
    color='green', alpha=0.2, label='IP 95%'
)

ax.set_title(f'Previsão Auto-ARIMA (d=1, D=auto) com Guerrero',
             fontsize=16)
ax.set_ylabel('Emissão CO2eq (mt)')
ax.legend(loc='upper left')
ax.grid(True, alpha=0.3)

plt.tight_layout()
plt.show()

# Gráfico 2: Diagnóstico dos Resíduos
modelo_auto_d_travado.plot_diagnostics(figsize=(15, 10))
plt.suptitle('Diagnóstico de Resíduos - Auto-ARIMA', y=1.02)
plt.show()

```

```

Performing stepwise search to minimize aic
ARIMA(0,1,0)(0,0,1)[12] intercept : AIC=0.949, Time=0.12 sec
ARIMA(0,1,0)(0,0,0)[12] intercept : AIC=4.671, Time=0.03 sec
ARIMA(1,1,0)(1,0,0)[12] intercept : AIC=-0.285, Time=0.26 sec
ARIMA(0,1,1)(0,0,1)[12] intercept : AIC=0.869, Time=0.16 sec
ARIMA(0,1,0)(0,0,0)[12] intercept : AIC=2.678, Time=0.03 sec
ARIMA(1,1,0)(0,0,0)[12] intercept : AIC=4.678, Time=0.05 sec
ARIMA(1,1,0)(2,0,0)[12] intercept : AIC=0.480, Time=0.40 sec
ARIMA(1,1,0)(1,0,1)[12] intercept : AIC=-4.456, Time=0.43 sec
ARIMA(1,1,0)(0,0,1)[12] intercept : AIC=0.627, Time=0.14 sec

```

```

ARIMA(1,1,0)(2,0,1)[12] intercept : AIC=-2.680, Time=1.40 sec
ARIMA(1,1,0)(1,0,2)[12] intercept : AIC=-2.701, Time=1.21 sec
ARIMA(1,1,0)(0,0,2)[12] intercept : AIC=1.690, Time=0.45 sec
ARIMA(1,1,0)(2,0,2)[12] intercept : AIC=inf, Time=1.45 sec
ARIMA(0,1,0)(1,0,1)[12] intercept : AIC=-2.975, Time=0.32 sec
ARIMA(2,1,0)(1,0,1)[12] intercept : AIC=-2.468, Time=0.73 sec
ARIMA(1,1,1)(1,0,1)[12] intercept : AIC=-2.460, Time=0.79 sec
ARIMA(0,1,1)(1,0,1)[12] intercept : AIC=-4.357, Time=0.38 sec
ARIMA(2,1,1)(1,0,1)[12] intercept : AIC=-0.457, Time=0.74 sec
ARIMA(1,1,0)(1,0,1)[12] : AIC=-6.456, Time=0.23 sec
ARIMA(1,1,0)(0,0,1)[12] : AIC=-1.368, Time=0.07 sec
ARIMA(1,1,0)(1,0,0)[12] : AIC=-2.281, Time=0.08 sec
ARIMA(1,1,0)(2,0,1)[12] : AIC=-4.680, Time=0.65 sec
ARIMA(1,1,0)(1,0,2)[12] : AIC=-4.703, Time=0.54 sec
ARIMA(1,1,0)(0,0,0)[12] : AIC=2.684, Time=0.03 sec
ARIMA(1,1,0)(0,0,2)[12] : AIC=-0.308, Time=0.22 sec
ARIMA(1,1,0)(2,0,0)[12] : AIC=-1.519, Time=0.17 sec
ARIMA(1,1,0)(2,0,2)[12] : AIC=inf, Time=0.87 sec
ARIMA(0,1,0)(1,0,1)[12] : AIC=-4.975, Time=0.17 sec
ARIMA(2,1,0)(1,0,1)[12] : AIC=-4.468, Time=0.39 sec
ARIMA(1,1,1)(1,0,1)[12] : AIC=-4.460, Time=0.47 sec
ARIMA(0,1,1)(1,0,1)[12] : AIC=-6.357, Time=0.24 sec
ARIMA(2,1,1)(1,0,1)[12] : AIC=-2.483, Time=0.55 sec

```

Best model: ARIMA(1,1,0)(1,0,1)[12]

Total fit time: 13.797 seconds

--- Melhor modelo encontrado ---

SARIMAX Results

```

=====
=====
Dep. Variable:                                y      No. Observations: 192
Model: SARIMAX(1, 1, 0)x(1, 0, [1], 12)    Log Likelihood 7.228
Date: Fri, 21 Nov 2025          AIC           -6.456
Time: 20:08:23          BIC           6.553
Sample: 01-01-2008          HQIC          -1.187
                                         - 12-01-2023
Covariance Type:                            opg
=====
```

	coef	std err	z	P> z	[0.025	0.975]
ar.L1	0.1348	0.077	1.754	0.079	-0.016	0.285
ar.S.L12	0.9384	0.083	11.291	0.000	0.776	1.101

```

ma.S.L12      -0.8326      0.132      -6.308      0.000      -1.091      -0.574
sigma2        0.0534      0.004     14.445      0.000      0.046      0.061
=====
=====
Ljung-Box (L1) (Q):          0.00  Jarque-Bera (JB):
78.79
Prob(Q):                  0.97  Prob(JB):
0.00
Heteroskedasticity (H):    1.96  Skew:
0.51
Prob(H) (two-sided):       0.01  Kurtosis:
5.98
=====
=====

```

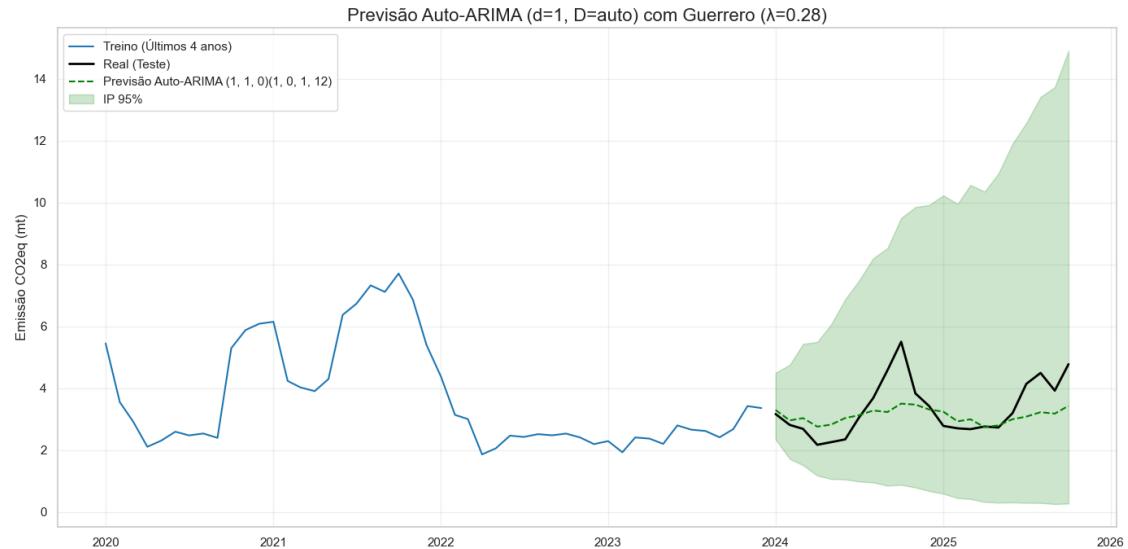
Warnings:

[1] Covariance matrix calculated using the outer product of gradients (complex-step).

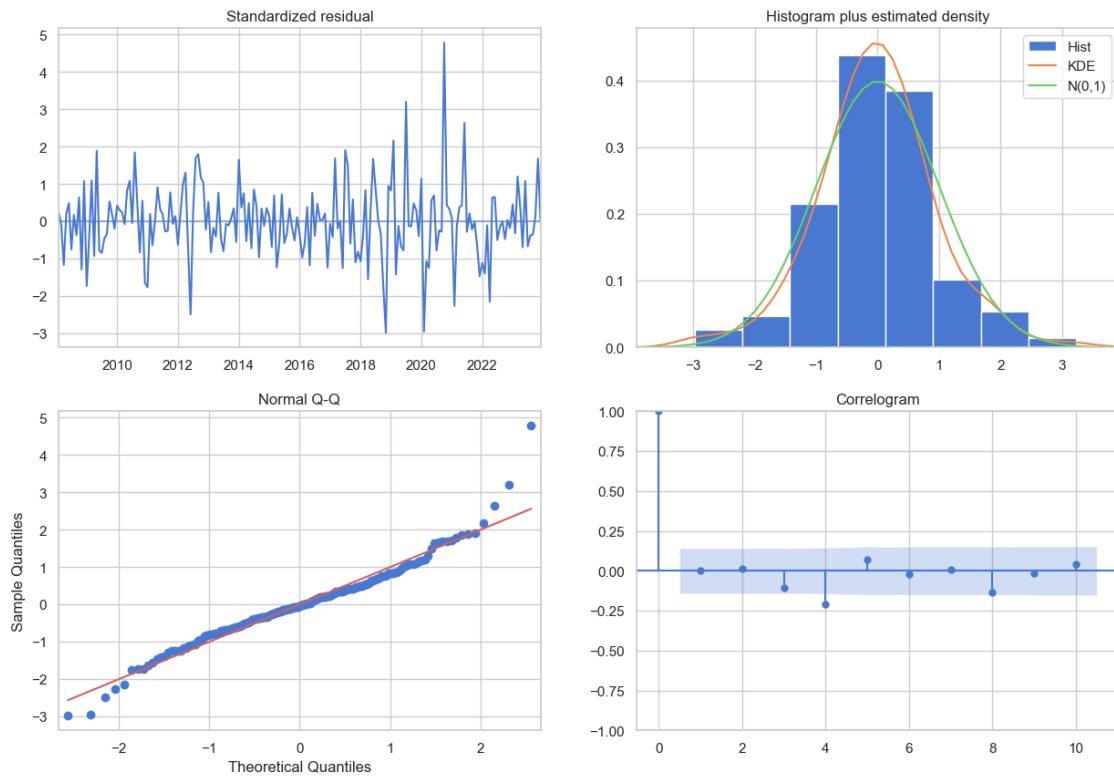
--- Resultados Auto-ARIMA (d=1, D=auto) ---

MAE: 0.5670

RMSE: 0.7666



Diagnóstico de Resíduos - Auto-ARIMA



```
[42]: # Treinamento do Auto-ARIMA (D=1 fixo, d via teste ADF)
# Configuração
modelo_auto_D_travado = pm.auto_arima(
    treino_guerrero,                      # Série transformada
    start_p=0, start_q=0,                  # Teste para achar o d (Tendência)
    test='adf',                           # Limites não sazonais
    max_p=3, max_q=3,                     # Período sazonal
    m=12,
    start_P=0,                           # Habilita o SARIMA
    seasonal=True,                        # teste 'adf' encontrar o d
    d=None,                               # Força a diferenciação sazonal
    D=1,
    trace=True,
    error_action='ignore',
    suppress_warnings=True,
    stepwise=True
)

print("\n--- Melhor modelo encontrado ---")
```

```

print(modelo_auto_D_travado.summary())

# Previsão e Inversão da Transformação

n_periodos = len(teste)

# Gerar previsões
pred_boxcox_D, conf_int_boxcox_D = modelo_auto_D_travado.predict(
    n_periods=n_periodos,
    return_conf_int=True,
    alpha=0.05
)

# Reverter Box-Cox (Voltar para CO2eq real)
pred_final_D = inv_boxcox(pred_boxcox_D, lambda_guerrero)
conf_int_final_D = inv_boxcox(conf_int_boxcox_D, lambda_guerrero)

# Avaliação de Métricas
mae_D = mean_absolute_error(teste, pred_final_D)
rmse_D = np.sqrt(mean_squared_error(teste, pred_final_D))

print(f"\n--- Resultados Auto-ARIMA (D=1 fixo, d=auto) ---")
print(f"MAE: {mae_D:.4f}")
print(f"RMSE: {rmse_D:.4f}")

# Gráfico 1: Previsão vs Real

fig, ax = plt.subplots(figsize=(14, 7))

# Dados de Treino (Recente)
ax.plot(treino.index[-48:], treino.tail(48), label='Treino', color='tab:blue')

# Dados Reais (Teste)
ax.plot(teste.index, teste, label='Teste', color='black', linewidth=2)

# Previsão
ax.plot(teste.index, pred_final_D, label=f'Previsão Auto-ARIMA_{modelo_auto_D_travado.order}{modelo_auto_D_travado.seasonal_order}', color='tab:red', linestyle='--')

# Intervalo de previsão
ax.fill_between(
    teste.index,
    conf_int_final_D[:, 0],
    conf_int_final_D[:, 1],
    color='tab:red', alpha=0.2, label='IP 95%'
)

```

```

ax.set_title(f'Previsão Auto-ARIMA (D=1 fixo) com Guerrero ( =lambda_guerrero:.
              ↪2f})', fontsize=16)
ax.set_ylabel('Emissão CO2eq (mt)')
ax.legend(loc='upper left')
ax.grid(True, alpha=0.3)

plt.tight_layout()
plt.show()

# Gráfico 2: Diagnóstico dos Resíduos
modelo_auto_D_travado.plot_diagnostics(figsize=(15, 10))
plt.suptitle('Diagnóstico de Resíduos - Auto-ARIMA (D=1 fixo)', y=1.02)
plt.show()

```

Performing stepwise search to minimize aic

ARIMA(0,0,0)(0,1,1)[12]	intercept : AIC=349.911, Time=0.17 sec
ARIMA(0,0,0)(0,1,0)[12]	intercept : AIC=370.038, Time=0.06 sec
ARIMA(1,0,0)(1,1,0)[12]	intercept : AIC=52.916, Time=0.34 sec
ARIMA(0,0,1)(0,1,1)[12]	intercept : AIC=186.421, Time=0.31 sec
ARIMA(0,0,0)(0,1,0)[12]	intercept : AIC=368.057, Time=0.03 sec
ARIMA(1,0,0)(0,1,0)[12]	intercept : AIC=89.951, Time=0.05 sec
ARIMA(1,0,0)(2,1,0)[12]	intercept : AIC=34.668, Time=0.87 sec
ARIMA(1,0,0)(2,1,1)[12]	intercept : AIC=15.589, Time=1.76 sec
ARIMA(1,0,0)(1,1,1)[12]	intercept : AIC=inf, Time=0.72 sec
ARIMA(1,0,0)(2,1,2)[12]	intercept : AIC=inf, Time=2.73 sec
ARIMA(1,0,0)(1,1,2)[12]	intercept : AIC=inf, Time=2.51 sec
ARIMA(0,0,0)(2,1,1)[12]	intercept : AIC=352.073, Time=0.69 sec
ARIMA(2,0,0)(2,1,1)[12]	intercept : AIC=11.481, Time=2.88 sec
ARIMA(2,0,0)(1,1,1)[12]	intercept : AIC=9.634, Time=1.50 sec
ARIMA(2,0,0)(0,1,1)[12]	intercept : AIC=7.935, Time=0.59 sec
ARIMA(2,0,0)(0,1,0)[12]	intercept : AIC=83.076, Time=0.10 sec
ARIMA(2,0,0)(0,1,2)[12]	intercept : AIC=9.569, Time=2.05 sec
ARIMA(2,0,0)(1,1,0)[12]	intercept : AIC=46.398, Time=0.43 sec
ARIMA(2,0,0)(1,1,2)[12]	intercept : AIC=inf, Time=2.50 sec
ARIMA(1,0,0)(0,1,1)[12]	intercept : AIC=12.121, Time=0.48 sec
ARIMA(3,0,0)(0,1,1)[12]	intercept : AIC=9.929, Time=0.92 sec
ARIMA(2,0,1)(0,1,1)[12]	intercept : AIC=10.261, Time=1.39 sec
ARIMA(1,0,1)(0,1,1)[12]	intercept : AIC=8.369, Time=0.59 sec
ARIMA(3,0,1)(0,1,1)[12]	intercept : AIC=11.856, Time=1.29 sec
ARIMA(2,0,0)(0,1,1)[12]	intercept : AIC=6.296, Time=0.57 sec
ARIMA(2,0,0)(0,1,0)[12]	intercept : AIC=81.078, Time=0.08 sec
ARIMA(2,0,0)(1,1,1)[12]	intercept : AIC=8.027, Time=0.61 sec
ARIMA(2,0,0)(0,1,2)[12]	intercept : AIC=8.005, Time=1.52 sec
ARIMA(2,0,0)(1,1,0)[12]	intercept : AIC=44.399, Time=0.22 sec
ARIMA(2,0,0)(1,1,2)[12]	intercept : AIC=inf, Time=3.23 sec
ARIMA(1,0,0)(0,1,1)[12]	intercept : AIC=10.330, Time=0.30 sec
ARIMA(3,0,0)(0,1,1)[12]	intercept : AIC=8.294, Time=0.43 sec

```

ARIMA(2,0,1)(0,1,1)[12] : AIC=8.295, Time=0.75 sec
ARIMA(1,0,1)(0,1,1)[12] : AIC=6.687, Time=0.38 sec
ARIMA(3,0,1)(0,1,1)[12] : AIC=10.231, Time=0.88 sec

```

```

Best model: ARIMA(2,0,0)(0,1,1)[12]
Total fit time: 33.983 seconds

```

--- Melhor modelo encontrado ---

SARIMAX Results

```

=====
=====
Dep. Variable: y No. Observations: 192
Model: SARIMAX(2, 0, 0)x(0, 1, [1], 12) Log Likelihood: 0.852
Date: Fri, 21 Nov 2025 AIC: 6.296
Time: 20:22:24 BIC: 19.068
Sample: 01-01-2008 HQIC: 11.475
- 12-01-2023
Covariance Type: opg
=====
=====

      coef    std err        z   P>|z|    [0.025    0.975]
-----
ar.L1     1.1105    0.073   15.110    0.000    0.966    1.255
ar.L2    -0.1818    0.074   -2.469    0.014   -0.326   -0.037
ma.S.L12 -0.8407    0.067  -12.623    0.000   -0.971   -0.710
sigma2    0.0530    0.004   12.525    0.000    0.045    0.061
=====

===
Ljung-Box (L1) (Q): 41.43 Jarque-Bera (JB):
                      0.00 Prob(JB):
                      0.00
Heteroskedasticity (H): 0.43 Skew:
                         1.91 Prob(H) (two-sided):
                         0.01 Kurtosis:
                         5.19
=====

===

```

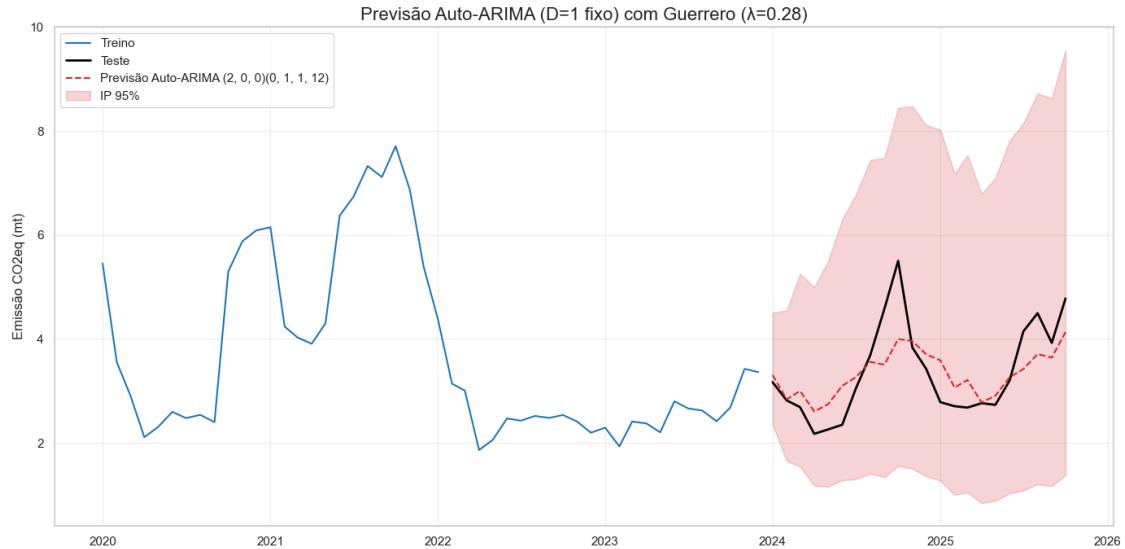
Warnings:

```
[1] Covariance matrix calculated using the outer product of gradients (complex-step).
```

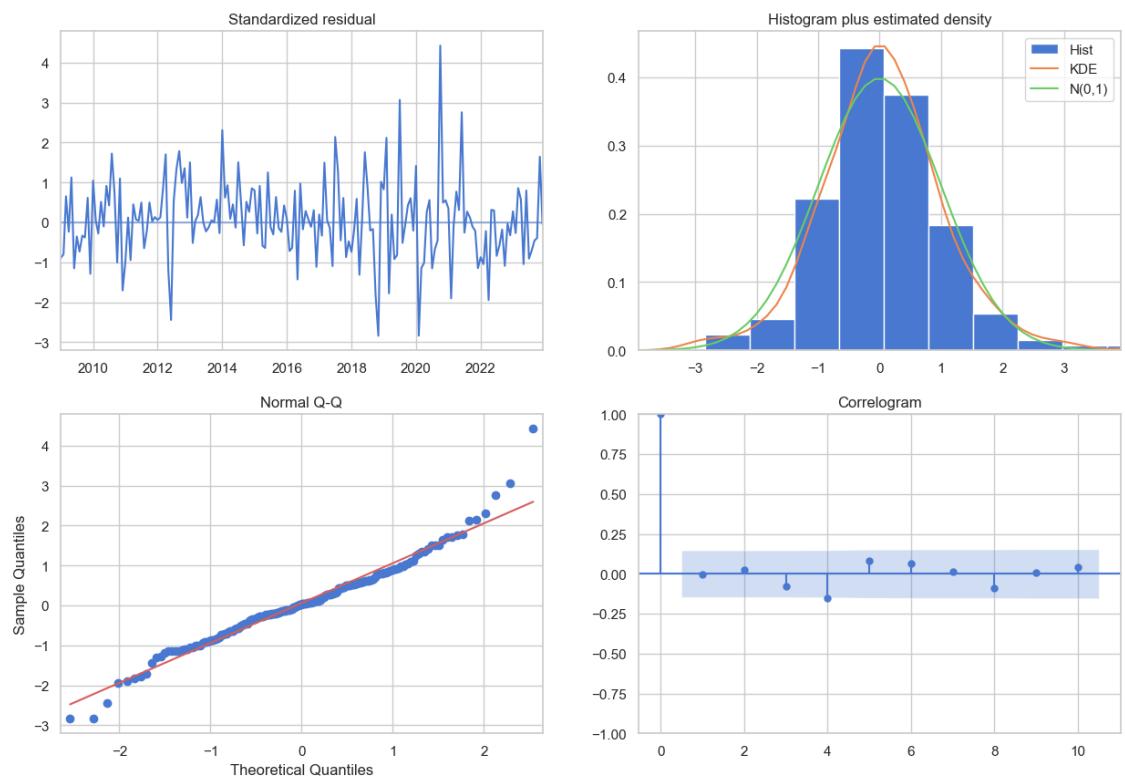
--- Resultados Auto-ARIMA (D=1 fixo, d=auto) ---

MAE: 0.4475

RMSE: 0.5802



Diagnóstico de Resíduos - Auto-ARIMA (D=1 fixo)



```
[43]: # Treinamento do Auto-ARIMA (d=1 e D=1 fixos)
print("--- Iniciando Auto-ARIMA (d=1 e D=1 fixos) ---")

# Configuração
modelo_auto_dD_travado = pm.auto_arima(
    treino_guerrero,                      # Série transformada
    start_p=0, start_q=0,
    max_p=3, max_q=3,
    m=12,                                # Período sazonal
    start_P=0,
    seasonal=True,                         # Habilita o SARIMA
    d=1,                                   # Força diferenciação de tendência
    D=1,                                   # Força diferenciação sazonal
    trace=True,
    error_action='ignore',
    suppress_warnings=True,
    stepwise=True
)

print("\n--- Melhor modelo encontrado (d=1, D=1) ---")
print(modelo_auto_dD_travado.summary())

# Previsão e Inversão da Transformação

n_periodos = len(teste)

# Gerar previsões
pred_boxcox_dD, conf_int_boxcox_dD = modelo_auto_dD_travado.predict(
    n_periods=n_periodos,
    return_conf_int=True,
    alpha=0.05
)

# Reverter Box-Cox (Voltar para CO2eq real)
pred_final_dD = inv_boxcox(pred_boxcox_dD, lambda_guerrero)
conf_int_final_dD = inv_boxcox(conf_int_boxcox_dD, lambda_guerrero)

# Avaliação de Métricas
mae_dD = mean_absolute_error(teste, pred_final_dD)
rmse_dD = np.sqrt(mean_squared_error(teste, pred_final_dD))

print(f"\n--- Resultados Auto-ARIMA (d=1, D=1 fixos) ---")
print(f"MAE: {mae_dD:.4f}")
print(f"RMSE: {rmse_dD:.4f}")
```

```

# Gráfico 1: Previsão vs Real

fig, ax = plt.subplots(figsize=(14, 7))

# Dados de Treino (Recente)
ax.plot(treino.index[-48:], treino.tail(48), label='Treino', color='tab:blue')

# Dados Reais (Teste)
ax.plot(teste.index, teste, label='Real (Teste)', color='black', linewidth=2)

# Previsão
ax.plot(teste.index, pred_final_dD, label=f'Previsão Auto-ARIMA',
        ↪{modelo_auto_dD_travado.order}{modelo_auto_dD_travado.seasonal_order}, ↪
        ↪color='tab:orange', linestyle='--')

# Intervalo de Previsão
ax.fill_between(
    teste.index,
    conf_int_final_dD[:, 0],
    conf_int_final_dD[:, 1],
    color='tab:orange', alpha=0.2, label='IP 95%'
)

ax.set_title(f'Previsão Auto-ARIMA (d=1, D=1 fixos) com Guerrero',
            ↪( =[lambda_guerrero:.2f}), fontsize=16)
ax.set_ylabel('Emissão CO2eq (mt)')
ax.legend(loc='upper left')
ax.grid(True, alpha=0.3)

plt.tight_layout()
plt.show()

# Gráfico 2: Diagnóstico dos Resíduos
modelo_auto_dD_travado.plot_diagnostics(figsize=(15, 10))
plt.suptitle('Diagnóstico de Resíduos - Auto-ARIMA (d=1, D=1)', y=1.02)
plt.show()

```

```

--- Iniciando Auto-ARIMA (d=1 e D=1 fixos) ---
Performing stepwise search to minimize aic
ARIMA(0,1,0)(0,1,1)[12] : AIC=13.618, Time=0.19 sec
ARIMA(0,1,0)(0,1,0)[12] : AIC=94.163, Time=0.03 sec
ARIMA(1,1,0)(1,1,0)[12] : AIC=54.206, Time=0.16 sec
ARIMA(0,1,1)(0,1,1)[12] : AIC=11.393, Time=0.33 sec
ARIMA(0,1,1)(0,1,0)[12] : AIC=92.415, Time=0.05 sec
ARIMA(0,1,1)(1,1,1)[12] : AIC=13.309, Time=0.52 sec
ARIMA(0,1,1)(0,1,2)[12] : AIC=13.299, Time=0.90 sec
ARIMA(0,1,1)(1,1,0)[12] : AIC=54.337, Time=0.15 sec

```

```

ARIMA(0,1,1)(1,1,2) [12] : AIC=inf, Time=2.40 sec
ARIMA(1,1,1)(0,1,1) [12] : AIC=13.368, Time=0.50 sec
ARIMA(0,1,2)(0,1,1) [12] : AIC=13.311, Time=0.60 sec
ARIMA(1,1,0)(0,1,1) [12] : AIC=11.460, Time=0.44 sec
ARIMA(1,1,2)(0,1,1) [12] : AIC=11.228, Time=1.13 sec
ARIMA(1,1,2)(0,1,0) [12] : AIC=94.292, Time=0.12 sec
ARIMA(1,1,2)(1,1,1) [12] : AIC=13.136, Time=1.68 sec
ARIMA(1,1,2)(0,1,2) [12] : AIC=inf, Time=2.36 sec
ARIMA(1,1,2)(1,1,0) [12] : AIC=57.197, Time=0.40 sec
ARIMA(1,1,2)(1,1,2) [12] : AIC=inf, Time=2.92 sec
ARIMA(2,1,2)(0,1,1) [12] : AIC=5.974, Time=0.94 sec
ARIMA(2,1,2)(0,1,0) [12] : AIC=inf, Time=0.55 sec
ARIMA(2,1,2)(1,1,1) [12] : AIC=7.364, Time=1.42 sec
ARIMA(2,1,2)(0,1,2) [12] : AIC=7.317, Time=2.56 sec
ARIMA(2,1,2)(1,1,0) [12] : AIC=46.693, Time=0.75 sec
ARIMA(2,1,2)(1,1,2) [12] : AIC=9.252, Time=3.07 sec
ARIMA(2,1,1)(0,1,1) [12] : AIC=10.090, Time=1.22 sec
ARIMA(3,1,2)(0,1,1) [12] : AIC=7.973, Time=1.55 sec
ARIMA(2,1,3)(0,1,1) [12] : AIC=7.973, Time=1.44 sec
ARIMA(1,1,3)(0,1,1) [12] : AIC=10.835, Time=1.03 sec
ARIMA(3,1,1)(0,1,1) [12] : AIC=11.503, Time=0.97 sec
ARIMA(3,1,3)(0,1,1) [12] : AIC=9.258, Time=2.17 sec
ARIMA(2,1,2)(0,1,1) [12] intercept : AIC=7.916, Time=1.68 sec

```

Best model: ARIMA(2,1,2)(0,1,1) [12]

Total fit time: 34.232 seconds

--- Melhor modelo encontrado (d=1, D=1) ---

SARIMAX Results

=====

Dep. Variable: y No. Observations: 192

Model: SARIMAX(2, 1, 2)x(0, 1, [1], 12)

Log Likelihood 3.013

Date: Fri, 21 Nov 2025

AIC 5.974

Time: 20:27:53

BIC 25.098

Sample: 01-01-2008

HQIC 13.729

- 12-01-2023

Covariance Type: opg

	coef	std err	z	P> z	[0.025	0.975]
ar.L1	0.7518	0.081	9.253	0.000	0.593	0.911
ar.L2	-0.8973	0.079	-11.414	0.000	-1.051	-0.743

```

ma.L1      -0.6190    0.103   -5.982    0.000   -0.822   -0.416
ma.L2      0.8402    0.092    9.179    0.000    0.661   1.020
ma.S.L12   -0.8673    0.086   -10.090   0.000   -1.036   -0.699
sigma2     0.0516    0.004   12.466    0.000    0.044   0.060
=====
=====
Ljung-Box (L1) (Q):          0.00  Jarque-Bera (JB):
52.81                         Prob(Q):       0.98  Prob(JB):
0.00
Heteroskedasticity (H):      1.54  Skew:
0.53
Prob(H) (two-sided):         0.10  Kurtosis:
5.44
=====
=====

```

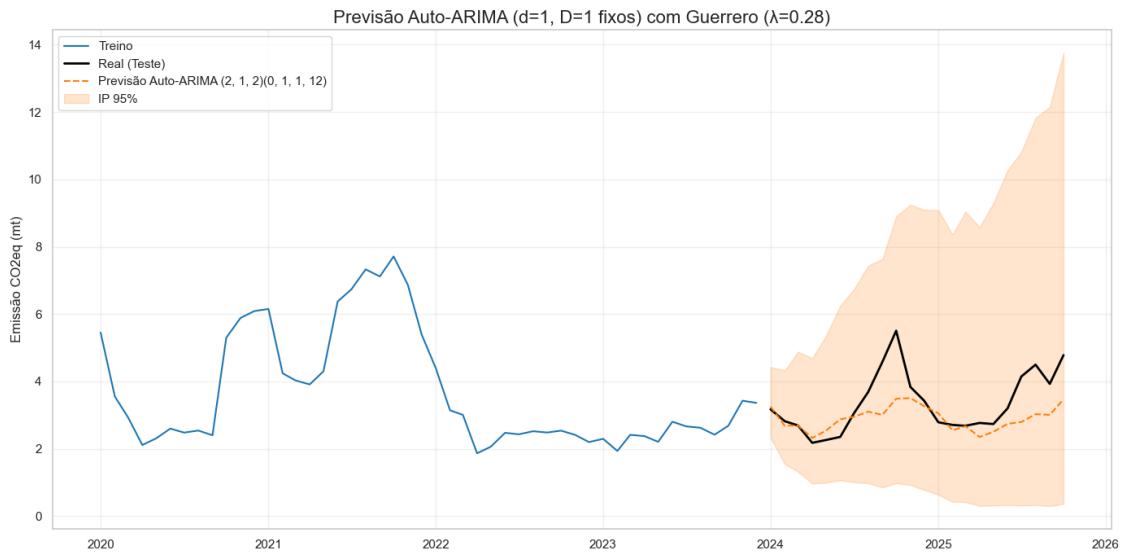
Warnings:

[1] Covariance matrix calculated using the outer product of gradients (complex-step).

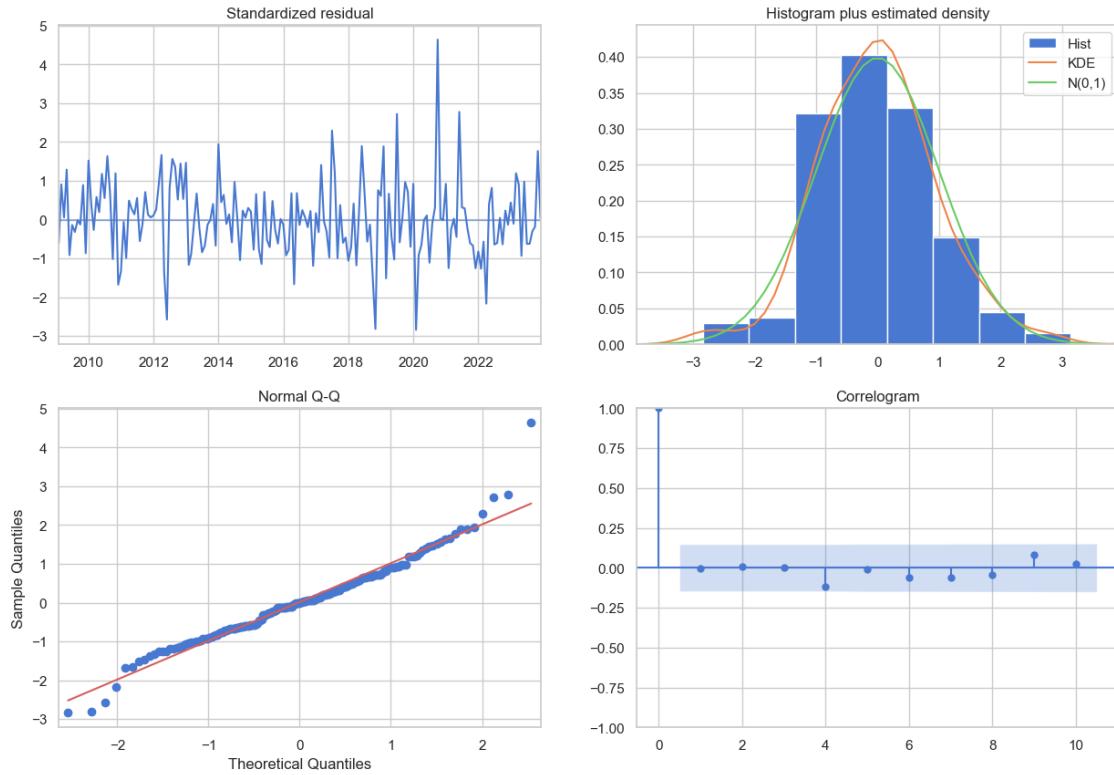
--- Resultados Auto-ARIMA (d=1, D=1 fixos) ---

MAE: 0.5705

RMSE: 0.8132



Diagnóstico de Resíduos - Auto-ARIMA (d=1, D=1)



```
[ ]: # AutoETS com statsforecast
from statsforecast import StatsForecast
from statsforecast.models import AutoETS
import pandas as pd

# Preparar o formato que o StatsForecast exige (unique_id, ds, y)
df_treino_sf = pd.DataFrame({
    'unique_id': 'co2_eq',
    'ds': treino.index,
    'y': treino.values
})

# Instanciar o AutoETS
# season_length=12
# ZZZ (Padrão do R) para auto seleção de modelos
sf = StatsForecast(
    models=[AutoETS(model='ZZZ', season_length=12)],
    freq='MS'
)
```

```

# Ajustar o modelo
sf.fit(df_treino_sf)

# Prever
h = len(teste)
previsao_sf = sf.predict(h=h)

# Extrair resultado para plotar
previsao_ets = pd.Series(previsao_sf['AutoETS'].values, index=teste.index)

print("--- Modelo AutoETS Selecionado ---")

# Métricas
from sklearn.metrics import mean_absolute_error, mean_squared_error
import numpy as np

mae_ets = mean_absolute_error(teste, previsao_ets)
rmse_ets = np.sqrt(mean_squared_error(teste, previsao_ets))

print(f"MAE: {mae_ets:.4f}")
print(f"RMSE: {rmse_ets:.4f}")

# Pegar o modelo treinado da primeira série (índice 0) e primeiro modelo
# (índice 0)
modelo_treinado = sf.fitted_[0, 0]

nome_modelo = modelo_treinado.model_['method']

print(f" O AutoETS escolheu o modelo: {nome_modelo}")

# 5. Visualização
import matplotlib.pyplot as plt

fig, ax = plt.subplots(figsize=(14, 7))
ax.plot(treino.index[-48:], treino.tail(48), label='Treino ', color='tab:blue')
ax.plot(teste.index, teste, label='Teste', color='black', linewidth=2)
ax.plot(teste.index, previsao_ets, label='Previsão AutoETS', color='red', 
        linestyle='--')
ax.set_title('AutoETS vs Dados Reais')
ax.legend()
ax.grid(True, alpha=0.3)
plt.show()

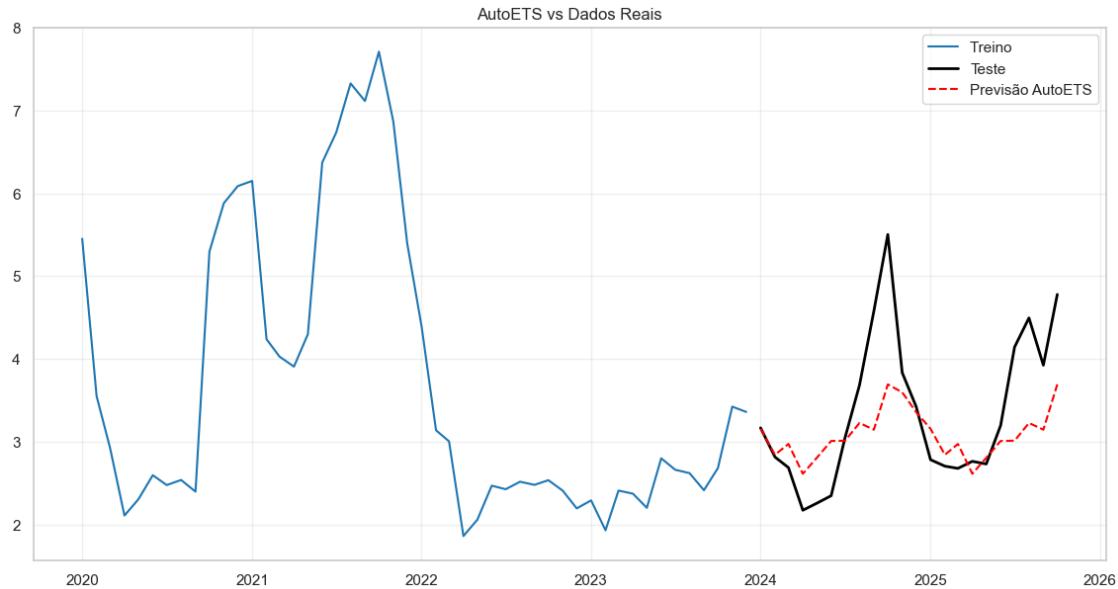
```

--- Modelo AutoETS Selecionado ---

MAE: 0.5228

RMSE: 0.7261

O AutoETS escolheu o modelo: ETS(M,N,M)



```
[46]: # Auto_ETS com Box-Cox (Guerrero)
# Lista completa de configurações possíveis
# Notação: (Erro, Tendência, Sazonalidade) -> Sempre começa com A pois Box-Cox estabilizou a variância.

configs_ets = [
    # 1. Sem Sazonalidade (Final = N)
    ('A,N,N', {'trend': None, 'seasonal': None, 'damped_trend': False}), # SES
    ('A,A,N', {'trend': 'add', 'seasonal': None, 'damped_trend': False}), # Holt Linear
    ('A,Ad,N', {'trend': 'add', 'seasonal': None, 'damped_trend': True}), # Holt Amortecido

    # 2. Com Sazonalidade Aditiva (Final = A)
    ('A,N,A', {'trend': None, 'seasonal': 'add', 'damped_trend': False}), # Sazonal Simples
    ('A,A,A', {'trend': 'add', 'seasonal': 'add', 'damped_trend': False}), # Holt-Winters
    ('A,Ad,A', {'trend': 'add', 'seasonal': 'add', 'damped_trend': True}), # HW Amortecido
]
```

resultados = []

```

melhor_aic = float('inf')
vencedor_info = None

print(f"{'MODELO':<10} | {'AIC':<12} | {'MAE (Teste)':<12} | {'RMSE (Teste)':<12}")
print("-" * 55)

for nome, params in configs_ets:
    try:
        # 1. Instanciar e Treinar
        mdl = ExponentialSmoothing(
            treino_guerrero,
            seasonal_periods=12,
            trend=params['trend'],
            seasonal=params['seasonal'],
            damped_trend=params['damped_trend']
        )

        # Otimizar parâmetros
        fit = mdl.fit(optimized=True, remove_bias=False)

        # Prever
        pred_guerrero = fit.forecast(len(teste))

        # Destransformar (Voltar para CO2eq real)
        pred_real = inv_boxcox(pred_guerrero, lambda_guerrero)

        # Calcular métricas
        mae = mean_absolute_error(teste, pred_real)
        rmse = np.sqrt(mean_squared_error(teste, pred_real))

        # Guardar resultados
        resultados.append({
            'Modelo': nome,
            'AIC': fit.aic,
            'MAE': mae,
            'RMSE': rmse,
            'Previsão': pred_real,
            'Params': params
        })

        print(f"{nome:<10} | {fit.aic:<12.2f} | {mae:<12.4f} | {rmse:<12.4f}")

    except Exception as e:
        print(f"{nome:<10} | Falhou: Convergência não alcançada.")

# Tabela de Classificação

```

```

df_resultados = pd.DataFrame(resultados).sort_values(by='AIC')

if not df_resultados.empty:
    vencedor = df_resultados.iloc[0]

    print("-" * 55)
    print(f" MODELO VENCEDOR (AIC): ETS({vencedor['Modelo']})")
    print(f"    AIC: {vencedor['AIC']:.2f} | MAE: {vencedor['MAE']:.4f}")

    # Visualização do Modelo Vencedor
    fig, ax = plt.subplots(figsize=(14, 7))

    # Teste
    ax.plot(treino.index[-48:], treino.tail(48), label='Treino', color='tab:blue')
    ax.plot(teste.index, teste, label='Teste', color='black', linewidth=2)

    # Previsão
    pred_series = pd.Series(vencedor['Previsão'].values, index=teste.index)
    ax.plot(teste.index, pred_series,
            label=f"Previsão ETS({vencedor['Modelo']})",
            color='green', linestyle='--', linewidth=2)

    ax.set_title(f"Melhor Modelo ETS: {vencedor['Modelo']} \n(AIC={vencedor['AIC']:.1f})")
    ax.set_ylabel('Emissão CO2eq (mt)')
    ax.legend(loc='upper left')
    ax.grid(True, alpha=0.3)

    plt.tight_layout()
    plt.show()

    # Exibir tabela completa ordenada
    print("\n--- RANKING COMPLETO ---")
    print(df_resultados[['Modelo', 'AIC', 'MAE', 'RMSE']].round(4).
          to_string(index=False))

else:
    print("\n Nenhum modelo funcionou. Verifique os dados.")

```

MODELO	AIC	MAE (Teste)	RMSE (Teste)
<hr/>			
A,N,N	-541.19	0.7475	0.8836
A,A,N	-537.20	0.7457	0.8758
A,Ad,N	-535.21	0.7465	0.8785
A,N,A	-554.23	0.5099	0.7033

c:\Users\felipeaasl\Documents\Trabalho_séries_temporais\.venv\Lib\site-

```

packages\statsmodels\tsa\base\tsa_model.py:473: ValueWarning: No frequency
information was provided, so inferred frequency MS will be used.
    self._init_dates(dates, freq)
c:\Users\felipeaasl\Documents\Trabalho_séries_temporais\.venv\Lib\site-
packages\statsmodels\tsa\base\tsa_model.py:473: ValueWarning: No frequency
information was provided, so inferred frequency MS will be used.
    self._init_dates(dates, freq)
c:\Users\felipeaasl\Documents\Trabalho_séries_temporais\.venv\Lib\site-
packages\statsmodels\tsa\base\tsa_model.py:473: ValueWarning: No frequency
information was provided, so inferred frequency MS will be used.
    self._init_dates(dates, freq)
c:\Users\felipeaasl\Documents\Trabalho_séries_temporais\.venv\Lib\site-
packages\statsmodels\tsa\base\tsa_model.py:473: ValueWarning: No frequency
information was provided, so inferred frequency MS will be used.
    self._init_dates(dates, freq)
c:\Users\felipeaasl\Documents\Trabalho_séries_temporais\.venv\Lib\site-
packages\statsmodels\tsa\base\tsa_model.py:473: ValueWarning: No frequency
information was provided, so inferred frequency MS will be used.
    self._init_dates(dates, freq)
A,A,A      | -550.23      | 0.4994      | 0.6878
A,Ad,A     | -548.48       | 0.5085      | 0.7011
-----

```

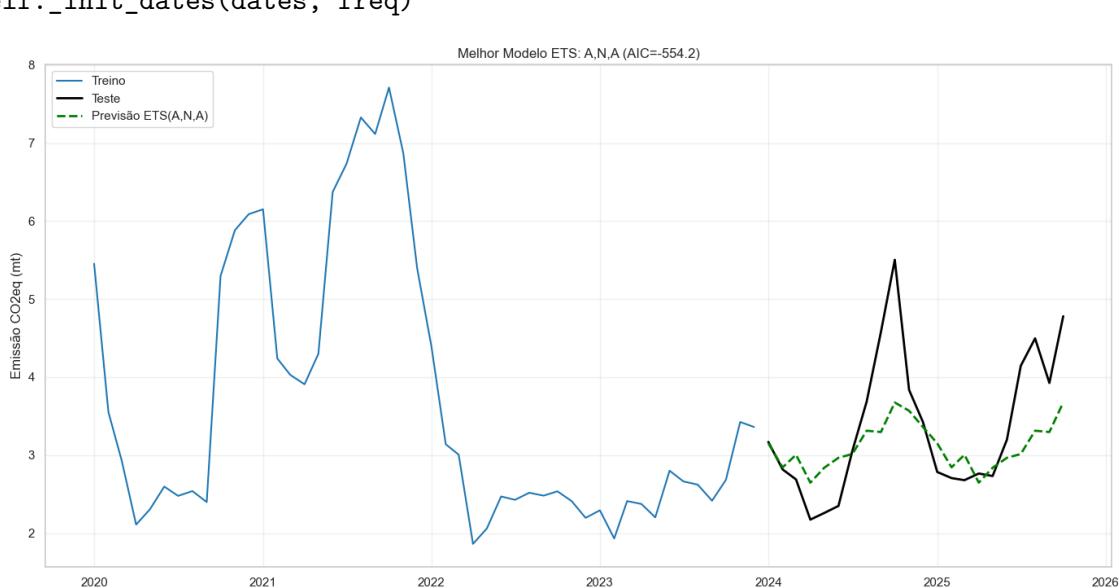
MODELO VENCEDOR (AIC): ETS(A,N,A)

AIC: -554.23 | MAE: 0.5099

```

c:\Users\felipeaasl\Documents\Trabalho_séries_temporais\.venv\Lib\site-
packages\statsmodels\tsa\base\tsa_model.py:473: ValueWarning: No frequency
information was provided, so inferred frequency MS will be used.
    self._init_dates(dates, freq)

```



```

--- RANKING COMPLETO ---
Modelo      AIC      MAE      RMSE
A,N,A -554.2296 0.5099 0.7033
A,A,A -550.2333 0.4994 0.6878
A,Ad,A -548.4806 0.5085 0.7011
A,N,N -541.1939 0.7475 0.8836
A,A,N -537.2007 0.7457 0.8758
A,Ad,N -535.2114 0.7465 0.8785

```

```

[50]: # Resultado dos modelos
# Benchmarks
n_test = len(teste)
last_val = treino_guerrero.iloc[-1]
y_pred_naive = np.full(n_test, inv_boxcox(last_val, lambda_guerrero))

last_year = treino_guerrero.iloc[-12:].values
reps = int(np.ceil(n_test / 12))
sna_guerrero = np.tile(last_year, reps)[:n_test]
y_pred_sna = inv_boxcox(sna_guerrero, lambda_guerrero)

media_movel = treino_guerrero.iloc[-12:].mean()
y_pred_ma = np.full(n_test, inv_boxcox(media_movel, lambda_guerrero))

# Definir Todos os Candidatos
modelos_finais = {
    # Benchmarks
    'Naïve': y_pred_naive,
    'SNaïve': y_pred_sna,
    'Média Móvel (12m)': y_pred_ma,

    # O ETS do StatsForecast (Dados Brutos)
    f'ETS({nome_modelo})': previsao_ets,

    # O ETS do Grid Search (Dados Transformados)
    f"ETS({vencedor['Modelo']})": vencedor['Previsão'],

    # SARIMAs
    'SARIMA(0,1,0)(2,1,1)[12]': pred_final_manual,
    f'SARIMA{modelo_auto_d_travado.order}{modelo_auto_d_travado.
    seasonal_order}': pred_final_auto,
    f'SARIMA{modelo_auto_D_travado.order}{modelo_auto_D_travado.
    seasonal_order}': pred_final_D,
    f'SARIMA{modelo_auto_dD_travado.order}{modelo_auto_dD_travado.
    seasonal_order}': pred_final_dD,
}

```

```

# Calcular Métricas e Montar Tabela
resultados_gerais = []

for nome, previsao in modelos_finais.items():
    if previsao is None: continue
    try:
        # Padronizar formato (Series ou Array)
        vals = previsao.values if isinstance(previsao, pd.Series) else previsao

        mae = mean_absolute_error(teste, vals)
        rmse = np.sqrt(mean_squared_error(teste, vals))

        y_true = teste.values
        mape = np.mean(np.abs((y_true - vals) / y_true)) * 100

        resultados_gerais.append({'Modelo': nome, 'MAE': mae, 'RMSE': rmse, ▾
        ↵'MAPE (%)': mape})
    except Exception as e:
        print(f" Pulo: {nome} (Erro: {e})")

# Tabela Final
df_melhores = pd.DataFrame(resultados_gerais).sort_values(by='MAE').reset_index(drop=True)

print("=*85")
print(f"{'CLASSIFICAÇÃO FINAL DOS MODELOS':^85}")
print("=*85")
print(df_melhores.round(4).to_string(index=False))
print("-" * 85)

campeao = df_melhores.iloc[0]
print(f" VENCEDOR: {campeao['Modelo']} (MAE: {campeao['MAE']:.4f})")

# Gráfico Limpido
fig, ax = plt.subplots(figsize=(16, 9))

# Histórico
ax.plot(treino.index[-36:], treino.tail(36), label='Histórico', color='gray', ▾
    ↵alpha=0.4, linewidth=2)
ax.plot(teste.index, teste, label='REAL', color='black', linewidth=3, zorder=10)

# Cores Dinâmicas
cores = cm.get_cmap('tab10', len(df_melhores))

for i, row in df_melhores.iterrows():
    nome = row['Modelo']
    previsao = modelos_finais[nome]

```

```

# Transformar em Series para plotar com datas
if not isinstance(previsao, pd.Series):
    previsao = pd.Series(previsao, index=teste.index)

# Estilo
if i == 0: # Campeão
    estilo = '-'
    lw = 3.5
    alpha = 1.0
    # Legenda apenas com ícone e nome técnico
    label = f" {nome}"
else:
    estilo = '--'
    lw = 1.5
    alpha = 0.7
    # Legenda apenas com ranking e nome técnico
    label = f"{i+1}. {nome}"

ax.plot(teste.index, previsao, label=label, color=cores(i),  

        linestyle=estilo, linewidth=lw, alpha=alpha)

ax.set_title('Comparativo Final de Previsões', fontsize=16)
ax.set_ylabel('Emissão CO2eq (mt)')
# Legenda limpa posicionada fora para não poluir
ax.legend(bbox_to_anchor=(1.01, 1), loc='upper left', borderaxespad=0.,  

          fontsize=11)
ax.grid(True, alpha=0.3)
plt.tight_layout()
plt.show()

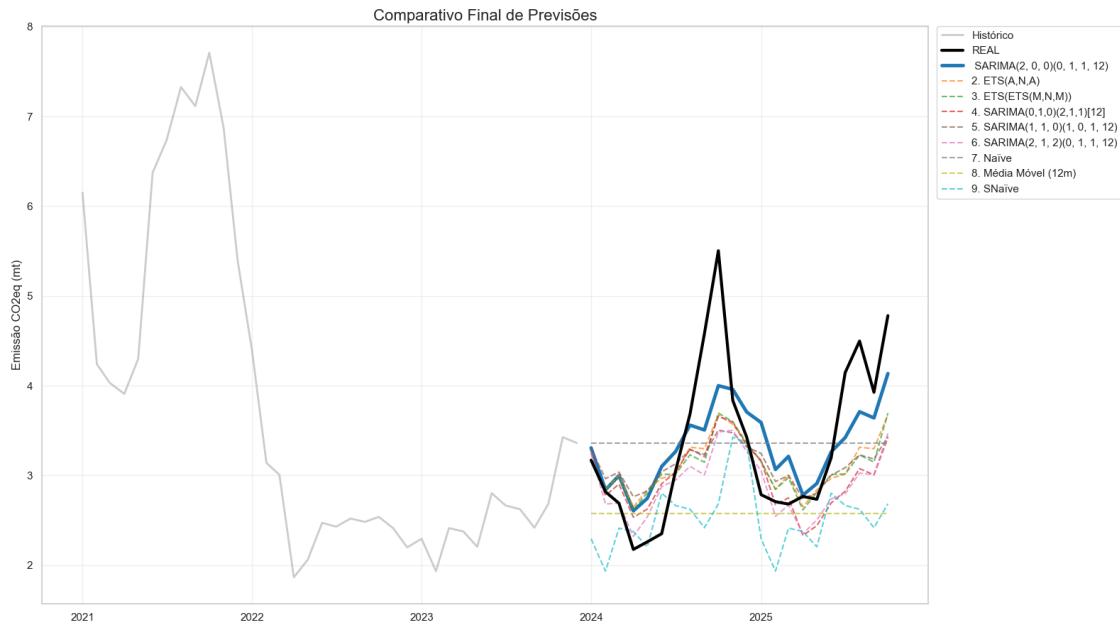
```

CLASSIFICAÇÃO FINAL DOS MODELOS

	Modelo	MAE	RMSE	MAPE (%)
SARIMA(2, 0, 0)(0, 1, 1, 12)	0.4475	0.5802	13.1378	
ETS(A,N,A)	0.5099	0.7033	13.9519	
ETS(ETS(M,N,M))	0.5228	0.7261	14.1929	
SARIMA(0,1,0)(2,1,1)[12]	0.5602	0.7771	14.8807	
SARIMA(1, 1, 0)(1, 0, 1, 12)	0.5670	0.7666	15.5698	
SARIMA(2, 1, 2)(0, 1, 1, 12)	0.5705	0.8132	14.6685	
Naïve	0.7475	0.8836	22.8973	
Média Móvel (12m)	0.8630	1.1768	21.9801	
SNaïve	0.8851	1.1650	23.4041	

```
-----
VENCEDOR: SARIMA(2, 0, 0)(0, 1, 1, 12) (MAE: 0.4475)

C:\Users\felipeaasl\AppData\Local\Temp\ipykernel_7080\3868011777.py:74:
MatplotlibDeprecationWarning: The get_cmap function was deprecated in Matplotlib
3.7 and will be removed in 3.11. Use ``matplotlib.colormaps[name]`` or
``matplotlib.colormaps.get_cmap()`` or ``pyplot.get_cmap()`` instead.
    cores = cm.get_cmap('tab10', len(df_melhores))
```



```
[52]: # Vizualização dos modelos
# cópia para arredondar apenas para visualização
df_display = df_melhores.copy()

# Arredondar colunas numéricas para 4 casas
cols_num = ['MAE', 'RMSE', 'MAPE (%)']
df_display[cols_num] = df_display[cols_num].round(4)

# Configurar a Figura
# Altura dinâmica baseada no número de modelos (para não ficar muito espremido
# ou sobrar muito espaço)
altura_fig = max(6, len(df_display) * 0.6 + 2)
fig, ax = plt.subplots(figsize=(16, altura_fig))

# Esconder eixos
ax.axis('off')
ax.axis('tight')
```

```

# Cores e Estilo
cor_cabecalho = '#40466e'      # Azul escuro profissional
cor_vencedor = '#dff0d8'        # Verde claro
cor_linhas_pares = '#f9f9f9'    # Cinza bem claro
cor_linhas_impares = '#ffffff'  # Branco
cor_fonte_cabecalho = 'white'
cor_melhor_metrica = '#fffecc2'

# Criar a Tabela
tabela = ax.table(cellText=df_display.values,
                   colLabels=df_display.columns,
                   loc='center',
                   cellLoc='center')

# Ajustes de Fonte e Escala
tabela.auto_set_font_size(False)
tabela.set_fontsize(12)
tabela.scale(1.0, 2.0) # Largura x Altura das células

# Iterar sobre as células para aplicar estilos
for (row, col), cell in tabela.get_celld().items():

    # Cabeçalho
    if row == 0:
        cell.set_text_props(weight='bold', color=cor_fonte_cabecalho)
        cell.set_facecolor(cor_cabecalho)
        cell.set_edgecolor('black')

    # Dados
    else:

        if row % 2 == 0:
            cell.set_facecolor(cor_linhas_pares)
        else:
            cell.set_facecolor(cor_linhas_impares)

        cell.set_edgecolor('lightgrey')

    # Destaque para o Vencedor (Linha 1, pois o cabeçalho é 0)
    # Como df_display já está ordenado por MAE, a linha 1 é o vencedor
    if row == 1:
        cell.set_facecolor(cor_vencedor)
        cell.set_text_props(weight='bold')
        # Borda mais grossa para o campeão
        cell.set linewidth(1.5)
        cell.set_edgecolor('#3c763d')

```

```

# Destacar a melhor métrica em cada coluna individualmente
# Mesmo que o vencedor do MAE ganhe, às vezes outro modelo tem melhor RMSE ou ↴MAPE
# +1 no índice por causa do cabeçalho
idx_min_mae = df_display['MAE'].idxmin() + 1
idx_min_rmse = df_display['RMSE'].idxmin() + 1
idx_min_mape = df_display['MAPE (%)'].idxmin() + 1

# Colunas: 0=Modelo, 1=MAE, 2=RMSE, 3=MAPE
# Negritar os valores recordistas
tabela[(idx_min_mae, 1)].set_text_props(weight='bold', color='black')
tabela[(idx_min_rmse, 2)].set_text_props(weight='bold', color='black')
tabela[(idx_min_mape, 3)].set_text_props(weight='bold', color='black')

# Título e Salvamento
plt.title(f' Resultado Final do Campeonato de Modelos (λ=0.28)', fontsize=18, weight='bold', pad=20, color='#333333')

plt.show()

```

Resultado Final do Campeonato de Modelos ($\lambda=0.28$)

Modelo	MAE	RMSE	MAPE (%)
SARIMA(2, 0, 0)(0, 1, 1, 12)	0.4475	0.5802	13.1378
ETS(A,N,A)	0.5099	0.7033	13.9519
ETS(ETS(M,N,M))	0.5228	0.7261	14.1929
SARIMA(0,1,0)(2,1,1)[12]	0.5602	0.7771	14.8807
SARIMA(1, 1, 0)(1, 0, 1, 12)	0.567	0.7666	15.5698
SARIMA(2, 1, 2)(0, 1, 1, 12)	0.5705	0.8132	14.6685
Naive	0.7475	0.8836	22.8973
Média Móvel (12m)	0.863	1.1768	21.9801
SNaive	0.8851	1.165	23.4041

[55]: # Previsão modelo vencedor final
Modelo: SARIMA(2,0,0)(0,1,1)[12]

```

# Preparação da Série Completa (União de Treino + Teste)
# O df_focado já contém todo o histórico desde 2008 até o último dado de 2025.
serie_completa = df_focado.set_index('data')['co2_mt']

```

```

print(f"--- Treinando Modelo Final ---")
print(f"Período: {serie_completa.index.min().date()} até {serie_completa.index.
    .max().date()}")
print(f"Total de observações: {len(serie_completa)}")

# Transformação Box-Cox na Série Completa
# Aplicar o lambda_guerrero em toda a série agora.
print(f"Aplicando transformação Box-Cox com  = {lambda_guerrero:.4f}")

serie_completa_boxcox = pd.Series(
    stats.boxcox(serie_completa, lmbda=lambda_guerrero),
    index=serie_completa.index
)

# Treinamento
modelo_final = pm.ARIMA(
    order=(2, 0, 0),                      # Parâmetros do Vencedor (p, d, q)
    seasonal_order=(0, 1, 1, 12), # Parâmetros do Vencedor (P, D, Q, m)
    suppress_warnings=True
)

modelo_final.fit(serie_completa_boxcox)

print("\nResumo do Modelo Final:")
print(modelo_final.summary())

# Previsão para o Futuro (Nov/2025 a Dez/2026)
n_previsao = 14
pred_boxcox, conf_int_boxcox = modelo_final.predict(
    n_periods=n_previsao,
    return_conf_int=True,
    alpha=0.05
)

# Reverter a Transformação (Voltar para CO2eq real)
pred_real = inv_boxcox(pred_boxcox, lambda_guerrero)
conf_int_real = inv_boxcox(conf_int_boxcox, lambda_guerrero)

# Criar DataFrame com as datas futuras
datas_futuras = pd.date_range(
    start=serie_completa.index.max() + pd.DateOffset(months=1),
    periods=n_previsao,
    freq='MS'
)

df_futuro = pd.DataFrame({
    'Previsão (CO2eq)': pred_real.values,
}

```

```

    'Limite Inferior': conf_int_real[:, 0],
    'Limite Superior': conf_int_real[:, 1]
}, index=datas_futuras)

print("\n--- Projeção (2025-2026) ---")
print(df_futuro.round(4))

# Visualização Final
fig, ax = plt.subplots(figsize=(15, 8))

# Plotar histórico recente
# Plot série sem transformação
ax.plot(serie_completa['2020'], label='Dados Históricos', color='tab:blue', linewidth=2)

# Plotar Previsão
ax.plot(df_futuro.index, df_futuro['Previsão (C02eq)'],
        label='Previsão SARIMA(2,0,0)(0,1,1)[12]',
        color='green', linestyle='--', linewidth=2)

# Intervalo de Previsão
ax.fill_between(
    df_futuro.index,
    df_futuro['Limite Inferior'],
    df_futuro['Limite Superior'],
    color='green', alpha=0.2, label='IP 95%'
)

ax.set_title('Previsão de Emissão de C02eq - Modelo SARIMA(2,0,0)(0,1,1)[12]', fontsize=16)
ax.set_ylabel('Emissão C02eq (mt)')
ax.legend(loc='upper left')
ax.grid(True, alpha=0.3)

plt.tight_layout()
plt.show()

```

--- Treinando Modelo Final ---
Período: 2008-01-01 até 2025-10-01
Total de observações: 214
Aplicando transformação Box-Cox com $\lambda = 0.2786$

Resumo do Modelo Final:

SARIMAX Results

=====

Dep. Variable: y No. Observations: 214

```

214
Model: SARIMAX(2, 0, 0)x(0, 1, [1], 12) Log Likelihood
5.687
Date: Fri, 21 Nov 2025 AIC
-1.374
Time: 21:48:22 BIC
15.167
Sample: 01-01-2008 HQIC
5.318
- 10-01-2025
Covariance Type: opg
=====
          coef    std err      z   P>|z|    [0.025    0.975]
-----
intercept  0.0022  0.003   0.645    0.519   -0.004    0.009
ar.L1       1.0971  0.070  15.569    0.000    0.959    1.235
ar.L2      -0.1737  0.071  -2.449    0.014   -0.313   -0.035
ma.S.L12   -0.8729  0.070 -12.474    0.000   -1.010   -0.736
sigma2      0.0505  0.004  12.370    0.000    0.042    0.058
=====
===
Ljung-Box (L1) (Q): 0.00 Jarque-Bera (JB):
42.90
Prob(Q): 1.00 Prob(JB):
0.00
Heteroskedasticity (H): 1.30 Skew:
0.37
Prob(H) (two-sided): 0.28 Kurtosis:
5.13
=====
===
Warnings:
[1] Covariance matrix calculated using the outer product of gradients (complex-step).

--- Projeção (2025-2026) ---
          Previsão (CO2eq) Limite Inferior Limite Superior
2025-11-01        4.5528     3.3686     6.0114
2025-12-01        4.2620     2.6749     6.4367
2026-01-01        4.0070     2.2295     6.6317
2026-02-01        3.5489     1.7740     6.3441
2026-03-01        3.6484     1.7205     6.7903
2026-04-01        3.2325     1.4061     6.3507
2026-05-01        3.3592     1.4172     6.7324
2026-06-01        3.6813     1.5426     7.4103
2026-07-01        4.0219     1.6846     8.0981
2026-08-01        4.4054     1.8557     8.8380

```

2026-09-01	4.3845	1.8164	8.8911
2026-10-01	5.0084	2.1259	9.9980
2026-11-01	4.7136	1.9338	9.6186
2026-12-01	4.4001	1.7417	9.1847

